



LAPORAN UTS MACHINE LEARNING 2026

Informasi Mahasiswa

Nama: Sholahuddin Yusuf Al Ayubi

NIM: 2411070071

Project Link (W&B): <https://wandb.ai/sholahuddin-y-a-stikomelrahma/breast-cancer-classification/runs/ow304hgx?nw=nwusersholahuddinya>

Pull Request Link (GitHub): http://github.com/addinsalim/Machine-Learning-Course-2026/tree/main/assignments/week-08/2411070071_Sholahuddin%20Yusuf%20Al%20Ayubi

1. Problem Statement & Dataset

Dataset yang digunakan dalam penelitian ini adalah **Breast Cancer Dataset** yang disediakan oleh library Scikit-Learn. Dataset ini berisi berbagai fitur numerik yang merepresentasikan karakteristik sel tumor, dengan target berupa klasifikasi:

- 0 = Malignant (Ganas)
- 1 = Benign (Jinak)

Permasalahan yang ingin diselesaikan adalah **klasifikasi (classification)**, yaitu memprediksi apakah suatu tumor termasuk ganas atau jinak berdasarkan fitur yang tersedia.

Masalah ini sangat penting untuk diselesaikan menggunakan Machine Learning karena:

- Diagnosis kanker secara manual memerlukan waktu dan biaya tinggi
 - Kesalahan diagnosis dapat berdampak fatal terhadap pasien
 - Model ML dapat membantu sebagai **decision support system** bagi tenaga medis
-

2. Exploratory Data Analysis (EDA)

Berdasarkan analisis awal data:

- Distribusi kelas menunjukkan bahwa data relatif **seimbang**, meskipun kelas jinak (benign) sedikit lebih banyak dibandingkan ganas (malignant).
- Tidak terdapat ketimpangan (imbalance) yang ekstrem sehingga model tidak terlalu bias terhadap satu kelas.

Dari visualisasi **correlation heatmap**, ditemukan bahwa:

- Beberapa fitur memiliki korelasi yang cukup tinggi satu sama lain
- Hal ini menunjukkan adanya kemungkinan redundansi fitur, namun tidak dilakukan penghapusan karena model seperti Random Forest mampu menangani hal tersebut

Visualisasi utama yang digunakan:

- Countplot distribusi target
- Heatmap korelasi fitur

Insight utama:

Data memiliki struktur yang cukup jelas dan separable, sehingga cocok untuk model klasifikasi.

3. Preprocessing & Feature Engineering

Langkah preprocessing yang dilakukan:

- Pemisahan fitur (X) dan target (y)
- Pembagian data menjadi:
 - 80% data training
 - 20% data testing
- Menggunakan parameter **stratify** pada `train_test_split` untuk menjaga distribusi kelas tetap seimbang

Tidak dilakukan:

- Handling missing values → karena dataset sudah bersih
- Encoding → karena semua fitur sudah numerik
- Scaling → tidak wajib untuk model tree-based

Penanganan imbalance:

- Tidak dilakukan SMOTE karena data relatif seimbang

4. Eksperimen Model (Battle of Algorithms)

Tiga model yang digunakan dalam eksperimen:

1. Logistic Regression (Linear Model)
2. Decision Tree (Tree-based Model)
3. Random Forest (Ensemble Model)

Model	Accuracy	Precision	Recall	F1-Score
-------	----------	-----------	--------	----------

Logistic Regression	0.9561	0.97	0.94	0.95
Decision Tree	0.9298	0.91	0.93	0.92
Random Forest	0.9737	0.98	0.96	0.97

Analisis awal:

- Logistic Regression bekerja baik pada data linear
- Decision Tree mampu menangkap pola lebih kompleks
- Random Forest memberikan hasil terbaik karena menggabungkan banyak tree

5. Analisis Hasil & W&B Tracking

Berdasarkan hasil evaluasi dan tracking melalui Weights & Biases (W&B):

Model dengan performa terbaik adalah:

👉 **Random Forest**

Hal ini terlihat dari nilai:

- Accuracy tinggi
- F1-score paling stabil



Analisis Confusion Matrix

Dari confusion matrix, dapat dianalisis bahwa:

- False Positive: kasus jinak yang diprediksi sebagai ganas
- False Negative: kasus ganas yang diprediksi sebagai jinak

Dalam konteks medis:

False Negative adalah kesalahan paling berbahaya karena pasien yang sebenarnya sakit tidak terdeteksi.

Model Random Forest mampu meminimalkan kesalahan tersebut dibanding model lainnya.



Feature Importance

Berdasarkan analisis feature importance dari Random Forest:

- Beberapa fitur memiliki kontribusi yang lebih besar dalam menentukan hasil klasifikasi
- Fitur dengan nilai importance tinggi menunjukkan bahwa karakteristik tertentu dari sel tumor sangat berpengaruh dalam diagnosis

Insight:

Model tidak hanya melakukan prediksi, tetapi juga memberikan interpretasi terhadap faktor penting dalam diagnosis.

6. Kesimpulan & Rekomendasi

Kesimpulan:

- Model Machine Learning berhasil melakukan klasifikasi kanker dengan performa yang baik
- Random Forest menjadi model terbaik karena mampu menangani pola kompleks dan memberikan hasil stabil
- Sistem ini berpotensi digunakan sebagai alat bantu diagnosis

Namun, model ini **belum sepenuhnya siap digunakan di dunia nyata**, karena:

- Dataset masih terbatas (bukan data real-time)
 - Tidak mempertimbangkan faktor klinis lain
 - Belum dilakukan validasi eksternal
-

Rekomendasi Pengembangan

Untuk penelitian selanjutnya:

- Menggunakan dataset yang lebih besar dan real-world
 - Mencoba model lain seperti XGBoost atau Neural Network
 - Melakukan hyperparameter tuning
 - Mengintegrasikan model ke sistem aplikasi
-



Penutup

Model Machine Learning dapat menjadi alat bantu yang sangat powerful dalam bidang medis, khususnya dalam diagnosis penyakit. Namun, penggunaannya tetap harus didampingi oleh tenaga ahli untuk memastikan akurasi dan keamanan.