

LAPORAN PRAKTIKUM MINGGU 11

Generative AI & Retrieval-Augmented Generation (RAG)

Gemini PDF Chatbot (RAG)

Informasi Mahasiswa

Nama : Sholahuddin Yusuf Al Ayubi

NIM : 2411070071

Link W&B Project : <https://wandb.ai/sholahuddin-y-a-stikomelrahma/gemini-rag-chatbot?nw=nwuserssholahuddinya>

Link Repositori Proyek : <https://github.com/addinsalim/Generative-AI-Retrieval-Augmented-Generation-RAG-.git>

1. Konsep Large Language Models (LLM)

1.1 Apa yang dimaksud dengan fenomena *Hallucination* pada AI dan mengapa hal itu terjadi?

Jawaban:

Hallucination (halusinasi) pada Artificial Intelligence (AI) adalah fenomena ketika Large Language Model (LLM) menghasilkan informasi yang terdengar meyakinkan dan tersusun dengan baik secara tata bahasa, tetapi sebenarnya tidak sesuai fakta, tidak akurat, atau bahkan tidak memiliki sumber yang valid.

Hal tersebut terjadi karena beberapa alasan berikut.

1. Mekanisme Probabilistik

LLM bekerja dengan memprediksi kata berikutnya (*next-token prediction*) berdasarkan pola statistik dari data pelatihan. Model tidak melakukan pengecekan fakta secara langsung maupun penalaran layaknya manusia.

2. Knowledge Cut-off

Pengetahuan model terbatas pada data yang digunakan saat proses pelatihan. Oleh karena itu, model tidak mengetahui informasi terbaru maupun data privat yang belum pernah dipelajari.

3. Sifat Generatif

LLM dirancang untuk selalu berusaha memberikan jawaban. Ketika informasi yang dimiliki tidak mencukupi, model cenderung mengisi kekosongan informasi dengan asumsi yang terdengar masuk akal, namun belum tentu benar.

1.2 Bagaimana mekanisme Retrieval-Augmented Generation (RAG) mampu menutupi kelemahan LLM terhadap data terbaru maupun data privat?

Jawaban:

Retrieval-Augmented Generation (RAG) mengatasi keterbatasan tersebut dengan menggabungkan kemampuan pencarian informasi (*retrieval*) dengan kemampuan pembangkitan jawaban (*generation*). Alur kerja RAG pada proyek ini adalah sebagai berikut.

1. Penyimpanan Dokumen

Dokumen PDF diekstrak menjadi teks, kemudian dipecah menjadi beberapa bagian (*chunks*). Setiap *chunk* diubah menjadi *embedding* menggunakan model **gemini-embedding-2**, lalu disimpan ke dalam Vector Database (ChromaDB atau JSON lokal).

2. Retrieval

Ketika pengguna mengajukan pertanyaan, pertanyaan tersebut juga diubah menjadi *embedding*. Selanjutnya sistem melakukan pencarian kemiripan (*Cosine Similarity Search*) untuk mengambil beberapa *chunk* yang paling relevan (Top-K).

3. Generation

Potongan dokumen yang diperoleh dijadikan konteks tambahan pada prompt sebelum dikirim ke model **gemini-2.5-flash**. Model diinstruksikan untuk hanya menjawab berdasarkan konteks tersebut sehingga jawaban menjadi lebih akurat dan dapat meminimalkan terjadinya hallucination.

2. Eksperimen Preprocessing (Chunking Strategy)

Pada sistem RAG yang dibangun, dokumen dipecah menggunakan parameter berikut.

CHUNK_SIZE : 1000 karakter

CHUNK_OVERLAP : 200 karakter

Pengaruh Parameter terhadap Kualitas Jawaban AI

a. Chunk Size (Ukuran Potongan Teks)

Jika terlalu besar (misalnya lebih dari 2000 karakter):

- Satu *chunk* akan berisi terlalu banyak topik.
- Informasi yang tidak relevan (*noise*) ikut terbawa.
- Fokus jawaban AI dapat menurun.
- Berpotensi melebihi batas token konteks model.

Jika terlalu kecil (misalnya kurang dari 200 karakter):

- Informasi penting dapat terpotong.
- Hubungan antar kalimat menjadi hilang.
- AI akan lebih sulit memahami konteks dokumen secara utuh.

b. Chunk Overlap (Tumpang Tindih Antar Potongan)

Pada proyek ini digunakan **Chunk Overlap sebesar 200 karakter**.

Overlap berfungsi menjaga kesinambungan informasi pada batas antar *chunk* (*chunk boundary*). Dengan adanya overlap, informasi penting yang berada di akhir suatu *chunk* juga tersedia pada *chunk* berikutnya sehingga konteks tetap terjaga dengan baik.

3. Analisis Hasil: Baseline vs RAG

Lakukan pengujian dengan mengunggah sebuah file PDF ke dalam aplikasi, kemudian ajukan pertanyaan yang jawabannya terdapat pada dokumen tersebut.

Pertanyaan Pengujian

.....
.....

Hasil Pengujian

Kategori Tanpa RAG (Baseline) Dengan RAG

Konten

Kebenaran

Analisis Kritis

Jelaskan perubahan kualitas jawaban yang diperoleh setelah menggunakan RAG.

Apakah AI masih mengalami hallucination meskipun telah diberikan dokumen sebagai referensi? Jelaskan hasil analisis Anda berdasarkan pengujian yang telah dilakukan.

4. Eksplorasi Relevansi (Top-K)

Nilai default parameter pencarian dokumen pada proyek ini adalah **TOP_K = 3**.

Nilai K yang Dicoba

.....

Analisis

Jelaskan hasil pengamatan Anda mengenai pengaruh perubahan nilai **Top-K** terhadap kualitas jawaban AI.

Apakah mengambil lebih banyak dokumen selalu menghasilkan jawaban yang lebih baik, atau justru menambahkan informasi yang tidak relevan sehingga membuat model kurang fokus?

5. Dokumentasi Weights & Biases (W&B)

Proyek ini mengintegrasikan **@wandb/sdk** untuk memonitor konfigurasi sistem dan performa chatbot, seperti:

- Latency
- Similarity Score
- Jumlah Chunk
- Parameter Konfigurasi
- Informasi Retrieval

Screenshot Dashboard W&B

(Tempelkan screenshot dashboard W&B di sini.)

6. Kesimpulan dan Refleksi

6.1 Apa kendala terbesar saat menghubungkan dokumen PDF ke model AI?

Jawaban:

.....
.....

6.2 Bagaimana teknologi RAG dapat membantu mahasiswa di lingkungan kampus?

Jawaban:

Retrieval-Augmented Generation (RAG) memiliki potensi besar dalam membantu aktivitas akademik mahasiswa. Teknologi ini dapat dimanfaatkan sebagai asisten akademik yang mampu menjawab pertanyaan berdasarkan dokumen resmi kampus, seperti buku pedoman akademik, panduan skripsi, maupun peraturan akademik tanpa harus membaca ratusan halaman dokumen.

Selain itu, RAG juga dapat membantu mahasiswa memperoleh informasi mengenai silabus mata kuliah, kurikulum, beasiswa, kalender akademik, serta berbagai prosedur administrasi kampus dengan lebih cepat, akurat, dan sesuai dengan dokumen resmi yang dimiliki institusi.